

KLASIFIKASI TWEET BENCANA



DISASTER DETECTION SQUAD

**When chaos tweets, these are the people who read
between the flames:**

1

**Ahmad Izza
11220940000006**

2

**Dani Hidayat
11220940000014**

MISSION: DISASTER CLASSIFIED

1

**Exploratory Data
Analysis**

2

Preprocessing

3


Vectorization

4

Modeling:
Naive Bayes
Logistic Regression

5

Model Interpretability:
Analisis kesalahan klasifikasi
Named Entity Extraction
POS-based Feature Scoring



PROBLEM STATEMENT




THE PROBLEM

- **Twitter** kini menjadi salah satu sumber utama informasi saat terjadi bencana.
- Masyarakat bisa melaporkan kejadian secara **real-time** melalui tweet.
- Namun, tidak semua tweet dengan kata seperti "**ablaze**" benar-benar menggambarkan bencana, bisa jadi hanya **metafora**.
- **Contoh:**
 - 🔥 "The concert was ablaze!" → **bukan bencana**
 - 🔥 "The entire forest is ablaze." → **bencana**
- **Tujuan:** Membangun model (Naive Bayes & Logistic Regression) yang dapat mendeteksi apakah sebuah tweet benar-benar mengandung informasi bencana atau tidak.

DATASET

Dataset yang digunakan berasal dari Kaggle, berisi **10.876** tweet berbahasa Inggris yang terbagi menjadi **3.263** data test dan **7.613** data train yang telah diklasifikasi secara manual.

Label:



1: Tweet terkait bencana nyata




0: Tweet tidak terkait bencana





EXPLORATORY DATA

DISTRIBUSI TWEET



Contoh Tweet


Bukan tentang bencana:

- **"Total tweet fail! You are so beautiful inside and out Blaze On!"**
- **"Shark boy and lava girl for the third time today..."**
- **"My brains going to explode i need to leave this house..."**


Tentang bencana:

- **"Forest fire near La Ronge Sask. Canada"**
- **"70 Years After Atomic Bombs Japan Still Struggles..."**
- **"Russian 'food crematoria' provoke outrage..."**

DISTRIBUSI PANJANG TWEET



KATA PALING SERING MUNCUL





DATA PREPROCESSING

LANGKAH-LANGKAH PREPROCESSING

1

Mengubah semua teks menjadi huruf kecil (lowercase)

2

Menghapus URL, tanda baca, angka, dan karakter khusus

3

Menghapus stopwords (kata umum yang tidak bermakna)

4

Tokenisasi (memecah teks menjadi kata-kata)

5

Melakukan lemmatization (mengubah kata ke bentuk dasar)

CONTOH TWEET SEBELUM & SESUDAH PREPROCESSING:

BUKAN BENCANA


Tweet Asli: Had an awesome time visiting the CFC head office the ancop site and ablaze. Thanks to Tita Vida for taking care of us ??

Clean Tweet: awesome time visiting cfc head office ancop site ablaze thanks tita vida taking care u

BENCANA

Tweet Asli: Our Deeds are the Reason of this #earthquake May ALLAH Forgive us all

Clean Tweet: deed reason earthquake may allah forgive u



TEXT VECTORIZATION

TFIDFVECTORIZER

	fire	like	im	get	amp	via	new	one	dont	people
0	0.00000	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.000000
1	0.22082	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.000000
2	0.00000	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.000000
3	0.00000	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.305331
4	0.00000	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.000000

DENGAN PENGANTURAN:

- **gram_range=(1, 2):**
 - Artinya: model akan mempertimbangkan unigram (kata tunggal) dan bigram (2 kata berurutan).
- **max_features=10.000:**
 - hanya akan menyimpan maksimal 10.000 kata/fitur paling penting berdasarkan frekuensi di seluruh dokumen.

TF-IDF digunakan untuk mengubah teks menjadi fitur numerik berbobot, agar bisa digunakan oleh model machine learning.

FEATURE SELECTION

Metode: Chi-Square (SelectKBest)

Jumlah fitur terbaik dipilih: 3000 dari 10.000

Tujuan:

menghindari curse of dimensionality

Mengurangi fitur tidak relevan

Meningkatkan efisiensi dan performa model

DATA SPLITTING

Setelah proses Feature Selection (SelectKBest), data dibagi menjadi:

- **80% data latih → X_{train} , y_{train}**
- **20% data uji → X_{test} , y_{test}**
- **Menggunakan stratify=y untuk menjaga distribusi label tetap seimbang**

Note:

- **Data yang digunakan hanya berasal dari train (dataset pelatihan dari Kaggle).**
- **Dataset test dari Kaggle tidak digunakan dalam pelatihan maupun evaluasi karena tidak memiliki label target.**
- **Evaluasi model hanya dilakukan pada data uji hasil pembagian dari data train.**



TRAINING & EVALUATION

LOGISTIC REGRESSION

EVALUASI BASE MODEL

Metric	Kelas 0 (Bukan Bencana)	Kelas 1 (Bencana)
Precision	0.78	0.85
Recall	0.91	0.66
F1-Score	0.84	0.74

- **Accuracy: 80%**
- **Model cenderung lebih baik mengenali non-bencana.**

HYPERPARAMETER TUNING

Menggunakan GridSearchCV dengan 5-fold cross-validation.


Parameter	Nilai yang Dicoba	Penjelasan
Penalty	l1, l2, elasticnet	penalty atau regularisasi digunakan untuk mencegah overfitting dengan menambahkan “penalty” terhadap kompleksitas model, khususnya terhadap nilai besar dari koefisien (parameter) model.
C	0.01, 0.1, 1, 10, 100	Nilai C yang kecil berarti regularisasi kuat (model lebih sederhana untuk mencegah overfitting).
Solver	'liblinear', 'lbfgs', 'newton-cg', 'newton-cholesky', 'sag', 'saga'	adalah metode numerik yang digunakan untuk menyelesaikan optimisasi fungsi loss

EVALUASI BEST MODEL

- **Parameter terbaik:**
 - **C=1, penalty="l2", solver='liblinear'**
- **Test Accuracy: 84%**
- **Tuning berhasil menyeimbangkan kinerja kedua kelas (disaster & non-disaster).**

Metric	Kelas 0 (Bukan Bencana)	Kelas 1 (Bencana)
Precision	0.85	0.83
Recall	0.88	0.79
F1-Score	0.86	0.81

CONFUSION MATRIX – BEST MODEL





TRAINING & EVALUATION


NAIVE BAYES

EVALUASI BASE MODEL

Metric	Kelas 0 (Bukan Bencana)	Kelas 1 (Bencana)
Precision	0.79	0.91
Recall	0.95	0.67
F1-Score	0.86	0.77

- **Accuracy: 82.7%**
- **Model cenderung lebih baik mengenali non-bencana, tapi banyak false negative untuk bencana.**

CONFUSION MATRIX – BASE MODEL



HYPERPARAMETER TUNING

Menggunakan GridSearchCV dengan 5-fold cross-validation.


Parameter	Nilai yang Dicoba	Penjelasan
alpha	0.01, 0.1, 0.5, 1.0, 2.0	Parameter smoothing yang mencegah probabilitas bernilai nol untuk kata-kata yang tidak muncul, sehingga model tetap dapat membuat prediksi yang stabil dan akurat.
fit_prior	True, False	Jika True, model belajar proporsi kelas dari data. Jika False, tidak.
class_prior	[0.5,0.5], [0.7,0.3], [0.9,0.1] (hanya jika fit_prior=True)	Proporsi manual untuk kelas 0 dan 1, misal memberi bobot lebih ke bencana.

EVALUASI BEST MODEL

- **Parameter terbaik:**
 - **alpha = 0.01, fit_prior = True, class_prior = [0.5, 0.5]**
- **Test Accuracy: 85.9%**
- **Tuning berhasil menyeimbangkan kinerja kedua kelas (disaster & non-disaster).**

Metric	Kelas 0 (Bukan Bencana)	Kelas 1 (Bencana)
Precision	0.86	0.86
Recall	0.90	0.81
F1-Score	0.88	0.83

CONFUSION MATRIX – BEST MODEL





ANALISIS KESALAHAN KLASIFIKASI

ANALISIS KESALAHAN KLASIFIKASI – NAIVE BAYES

SEHARUSNYA BENCANA, DIPREDIKSI BUKAN

- I waited 2.5 hours to get a cab my feet are bleeding
- @KatRamsland Yes I'm a bleeding heart liberal.
- @beckyfeigin I defs will when it stops bleeding!
- @Benjm1 @TourofUtah @B1Grego saw that pileup on TV keep racing even bleeding
- Watch how bad that fool get burned in coverage this year. Dat dude is all-pro practice squad material
- Destruction magic's fine just don't go burning down any buildings.
- @zourryart I forgot to add the burning buildings and screaming babies
- into burning fucking buildings (2/2)

SEHARUSNYA BUKAN BENCANA, DIPREDIKSI BENCANA

- Ali you flew planes and ran into burning buildings why are you making soup for that man child?!
#BooRadleyVanCullen
- if firefighters acted like cops they'd drive around shooting a flamethrower at burning buildings
- I crashed my car into a parked car the other day...
- Had a minute alone with my crush??...it was an overrated experience...smh
- Ari's hints and snippets will be the death of me.
- tomorrow will be the death of me
- @johndcgow heard this few days ago while driving and near crashed the car from laughing to much

ANALISIS KESALAHAN KLASIFIKASI – LOGISTIC REG.

SEHARUSNYA BENCANA, DIPREDIKSI BUKAN

- it wasnt a very big stab but it was a deep stab and theres like blood everwhe
- If a truckload of soldiers will be blown up nobody panics but when one little lion dies everyone loses their mind
- Even though BSG had been sufficiently hyped up for me in all the years I somehow delayed watching it I was utterly utterly blown away.
- drake killing this dude and tea bagging the dead body at this point

SEHARUSNYA BUKAN BENCANA, DIPREDIKSI BENCANA

- I crashed my car into a parked car the other day...
- VIDEO: Slain Mexican Journalist Unknowingly Predicted His Own Death
- Article by Michael Jackman at Metro Times Detroit
- Ashes 2015: Australia U's collapse at Trent Bridge among worst in history: England bundled out Australia for 60 ...
- Ali you flew planes and ran into burning buildings why are you making soup for that man child?!
- The Burning Legion has RETURNED!



DETEKSI LOKASI, WAKTU, DAN ORGANISASI

POS TAGGING – PROPER NOUNS EXTRACTION

- Menggunakan POS Tagging untuk mengekstrak kata benda khusus (Proper Noun: NNP, NNPS) dari tweet yang diklasifikasikan sebagai bencana.
- Fokus: Tweet dengan target = 1 (berisi informasi tentang bencana).
- Tokenisasi + POS Tagging + Ambil Proper Noun:

```
def extract_proper_nouns(text):  
    tokens = nltk.word_tokenize(text)  
    tagged = nltk.pos_tag(tokens)  
    proper_nouns = [word for word, tag in tagged if tag in ['NNP', 'NNPS']]  
    return proper_nouns
```

```
df_POS = disaster_df.copy()  
df_POS['proper_nouns'] = df_POS['text'].apply(extract_proper_nouns)
```


- Hitung frekuensi proper noun

```
from collections import Counter  
  
all_nouns = sum(df_POS['proper_nouns'], []) # Gabungkan semua kata  
noun_counts = Counter(all_nouns)  
  
# Buang kata pendek (<4 huruf)  
for key in list(noun_counts):  
    if len(key) < 4:  
        del noun_counts[key]  
  
top_nouns = noun_counts.most_common(15)
```

- Contoh hasil:
 - Tweet: Nearly 50 thousand people affected by floods in Paraguay
 - Proper Nouns: [Paraguay]

TOP 10 NNP TWEET BENCANA

(POS TAGGING – PROPER NOUNS EXTRACTION)



- Kata seperti **California**, **Hiroshima**, dan **Japan** paling sering muncul, menunjukkan lokasi kejadian.
- nama tokoh seperti **"Obama"** dan entitas seperti **"MH370"** juga muncul, yang dapat merepresentasikan konteks atau berita besar yang terkait bencana.
- Kehadiran kata seperti **"News"**, **"Police"**, dan **"Emergency"** menunjukkan bahwa tweet sering mengandung elemen pemberitaan atau respons instansi.


NAMED ENTITY RECOGNITION (NER) – BIO TAGGING

- Menggunakan model spaCy untuk mengenali entitas bernama dalam tweet (lokasi, waktu, organisasi, event).
- Format BIO (Beginning, Inside, Outside) digunakan untuk memberi label setiap token dalam teks.
- Dikembangkan dua fungsi:
 - `ner_bio()`: Melabeli setiap token dengan informasi entitas (misal: lokasi/waktu/organisasi/event).
 - `ner_bio2()`: mengekstrak entitas penting → lokasi, waktu, organisasi, event


```
def ner_bio(text):  
    doc = nlp(text) # Proses teks dengan spaCy  
    tokens = [token.text for token in doc]  
    tags = []  
    for token in doc:  
        ent = token.ent_iob_ # Ambil tag BIO ('B', 'I', 'O')  
        label = token.ent_type_ # Ambil tipe entitas (GPE, ORG, dll.)  
        if ent == 'O':  
            tags.append('O') # Token bukan entitas  
        else:  
            tags.append(f"{ent}-{label}") # Contoh: B-GPE  
    return list(zip(tokens, tags))
```

```
def ner_bio2(text):  
    doc = nlp(text)  
    # Simpan hasil entitas ke dalam list  
    loc, datetime, org, event = [], [], [], []  
    for token in doc:  
        label = token.ent_type_  
        # Klasifikasi berdasarkan jenis entitas  
        if label in ['GPE', 'LOC']:  
            loc.append(str(token))  
        if label in ['DATE', 'TIME']:  
            datetime.append(str(token))  
        if label == 'ORG':  
            org.append(str(token))  
        if label == 'EVENT':  
            event.append(str(token))  
    # Gabungkan hasil dalam bentuk string  
    return " ".join(loc), " ".join(datetime), " ".join(org), " ".join(event)
```


TOP 15 LOKASI TERATAS



TOP 15 WAKTU/PERIODE TERATAS



TOP 15 ORGANISASI TERATAS



INSIGHT

- **Lokasi paling sering disebut:**
 - **California, Hiroshima, dan Japan** muncul paling dominan dalam tweet bencana.
- **Waktu/Periode penting (dari NER):**
 - **Kata seperti today, tonight, dan Wednesday** sering digunakan, menandakan urgensi dan kejadian yang baru terjadi.
- **Organisasi/lembaga terkait:**
 - **MH370, PKK Turkey Army, dan Virgin Galactic** menjadi organisasi atau entitas yang paling sering dikaitkan dengan tweet bencana.
- **Perbandingan pendekatan:**
 - **POS Tagging** mendeteksi kata benda khusus (NNP) namun bisa kurang kontekstual.
 - **NER BIO** memberi label yang lebih spesifik seperti lokasi (LOC), waktu (TIME), dan organisasi (ORG), sehingga lebih informatif dan terstruktur.

KESIMPULAN

- **Model Naive Bayes menunjukkan performa yang lebih unggul dibanding Logistic Regression pada seluruh metrik evaluasi.**
- **Kedua model membuktikan bahwa metode machine learning masih sangat efektif dan efisien dalam menyelesaikan tugas klasifikasi teks, terutama saat dipadukan dengan feature engineering dan pre-processing yang tepat**

Metric	Logistic Regression	Naive Bayes
Precision	84%	86%
Recall	83%	85%
F1-Score	83%	86%
Akurasi	83.7%	85.9%



THANK YOU!
I HOPE YOU LEARN SOMETHING NEW TODAY!